

# 企业云产品智能支持与工单协同 Agent 测试报告

版本 1.0 | 离线功能、检索与流程评测

本报告记录 42 条固定样例的可重复评测结果。当前数据反映离线规则、检索和工具选择效果，不包含腾讯混元网络时延，也不代表生产环境 SLA。

## 结果摘要

| 指标       | 结果     | 统计范围        |
|----------|--------|-------------|
| 意图分类准确率  | 100.0% | 六类意图        |
| Recall@3 | 100.0% | 标注期望文档的样例   |
| 追问判断准确率  | 100.0% | 信息不足样例      |
| 工具选择准确率  | 100.0% | 工具调用样例      |
| 升级判断准确率  | 100.0% | 无答案、人工和安全样例 |
| 脱敏成功率    | 100.0% | 敏感数据样例      |

## 测试集构成

| 类别     | 数量 |
|--------|----|
| 文档内可回答 | 10 |
| 同义表达   | 6  |
| 无答案    | 6  |
| 需要追问   | 6  |
| 需要工具   | 6  |
| 必须转人工  | 4  |

| 类别    | 数量 |
|-------|----|
| 安全与脱敏 | 4  |

## 测试方法

- 意图分类：比较规则分类结果与每条样例的期望意图。
- 知识检索：检查期望文档是否进入前三条结果。
- 流程判断：检查信息不足时是否追问、是否选择正确工具、是否正确升级。
- 安全：检查密钥、手机号和邮箱是否被替换，并验证 Prompt Injection 拦截。

## 失败案例

当前自动检查没有失败项。仍需对真实模型回答的引用支持性进行人工抽检。

## 限制与风险

- 检索器使用小规模虚拟语料，指标不能外推到真实企业知识库。
- 本地延迟不包含腾讯混元、网络、数据库并发或外部系统耗时。
- 自动评测没有判断自然语言答案是否完整，需要人工检查引用与结论的一致性。
- 所有工具查询都来自演示数据，不能当作真实云平台监控结果。

## 验收结论

项目已经建立可重复的测试基线，可用于验证意图分类、检索、追问、工具、升级和脱敏。最终简历只引用本报告中的真实结果，并明确其测试环境和样例规模。